

Chapter 18

Variación Temporal y Espacial

Los métodos de simulación permiten explorar la dinámica poblacional bajo escenarios variables y condiciones no observadas directamente en los datos. Este capítulo introduce las simulaciones poblacionales como herramientas prospectivas para evaluar trayectorias futuras, variabilidad demográfica y respuestas a cambios en los procesos vitales.

Por: Raymond L. Tremblay

18.1 Simulaciones poblacionales y exploración de escenarios dinámicos

Las simulaciones poblacionales constituyen una extensión natural de los modelos matriciales al permitir proyectar poblaciones bajo condiciones variables, estocásticas o dependientes del tiempo. A diferencia de los análisis analíticos que se centran en el comportamiento asintótico, las simulaciones permiten explorar trayectorias transitorias, evaluar la variabilidad demográfica y analizar respuestas poblacionales ante cambios explícitos en los procesos vitales.

En este capítulo se presentan los fundamentos conceptuales de las simulaciones poblacionales, mostrando cómo pueden implementarse a partir de matrices de proyección y transiciones demográficas previamente definidas. Se discuten distintos tipos de simulaciones, incluyendo simulaciones determinísticas, estocásticas y basadas en escenarios, así como sus aplicaciones para evaluar extinción, recuperación y efectos de manejo.

Asimismo, se analiza el papel de las simulaciones como herramientas complementarias a enfoques analíticos como la elasticidad y los LTRE. Mientras estos últimos permiten identificar la importancia relativa o las causas de diferencias observadas, las simulaciones permiten evaluar **qué podría ocurrir** bajo condiciones alternativas. Este capítulo se diferencia de los anteriores porque se enfoca en la exploración explícita del futuro poblacional, integrando estructura demográfica, variabilidad y supuestos de manejo para generar predicciones y apoyar la toma de decisiones en ecología y biología de la conservación. Las simulaciones se construyen a partir de las transiciones demográficas introducidas en

el capítulo sobre transiciones poblacionales. Las trayectorias simuladas se interpretan en relación con la tasa de crecimiento poblacional discutida en el capítulo sobre crecimiento poblacional. A diferencia de los análisis LTRE, que explican diferencias observadas, las simulaciones permiten explorar escenarios futuros no observados. Las simulaciones pueden extenderse naturalmente dentro de un marco bayesiano, como se describe en el capítulo sobre modelos bayesianos de proyección poblacional.

18.1.0.1 Librerías de R requeridas para el siguiente módulo

```
library(tidyverse)
library(ggtext)
library(janitor)
library(popbio)
library(raretrans)
library(ggpubr)

rlt_theme <- theme(
  axis.title.y = element_text(colour = "grey20", size = 10, face = "bold"),
  axis.text.x = element_text(colour = "grey20", size = 10, face = "bold"),
  axis.text.y = element_text(colour = "grey20", size = 15, face = "bold"),
  axis.title.x = element_text(colour = "grey20", size = 15, face = "bold")
) +
  theme(
    # Remover los border
    panel.border = element_blank(),
    # Remover las lineas
    panel.grid.major = element_blank(),
    panel.grid.minor = element_blank(),
    # Remove el fondo del panel
    panel.background = element_blank(),
    # añadir lineas más gruesas
    axis.line.x = element_line(colour = "black", linewidth = 1),
    axis.line.y = element_line(colour = "black", linewidth = 1)
  )

diverging= c("#009392", "#CF597E", "#E9E29C", "#39B185", "#EEB479" , "#9CCB86" )

# --- 2. Combine them into a list object ---
# This list can be added to the plot with a single '+'
rlt_style_fill <- function() {
  list(
    rlt_theme,
    scale_fill_manual(values = diverging)
  )
}
```

```

    )
  }

  rlt_style_colour <- function() {
    list(
      rlt_theme,
      scale_colour_manual(values = diverging)
    )
  }

```

Implementación de simulaciones poblacionales

A continuación se describen los procedimientos para implementar simulaciones poblacionales a partir de matrices de proyección y transiciones demográficas, incluyendo ejemplos determinísticos y estocásticos.

El termino **biología** pudiese ser un sinónimo de variación biológica. No hay dos organismos iguales, ni siquiera gemelos/clones que sean completamente idénticos. La variación biológica es una característica fundamental de la vida y es la base de la evolución, no puede haber evolución sin variación. Cuando se considera los individuos, por ejemplos humanos, fácilmente reconocemos variación, en tamaño, color de ojos, susceptibilidad a cáncer o infección y efecto que tiene el ambiente (por ejemplo la dieta o acceso a la educación) entre muchos factores que impacta la supervivencia o crecimiento y reproducción. Pero desafortunadamente cuando se considera los animales y plantas de una misma especie frecuentemente se obvia la variación en los análisis. Podemos observar variación a múltiples niveles en una misma especie

- Variación sub-individual (dentro de un individuo), un concepto bien desarrollado por Carlos Herrera de la Universidad de Sevilla (Herrera, 2009). Esta variación nunca ha sido incluido en modelos MPP.
- Variación entre individuos (dentro de una población).
- Variación entre poblaciones (entre poblaciones).
- Variación entre tiempo (entre periodos de tiempo).

Todos estos componentes de variación tendrán impacto en la dispersión de los estimados de los parámetros de la matriz de transición y el crecimiento poblacional en adición del comportamiento de la población en tiempo. Hay un componente que frecuentemente se deja por olvido es el efecto de la variación en tamaño de muestra pequeña en los estimados de los parámetros de la matriz de transición y el crecimiento poblacional, este es el **efecto demográfico por tamaño de muestra**. En este capítulo se discute el efecto de la variación en tiempo y espacio en los estimados de los parámetros de la matriz de transición y el crecimiento poblacional. El efecto demográfico se discute en otros capítulos.

18.1.1 Componentes de Variación

18.1.1.1 La variación sub-individual

La variación sub-individual es la variación que se observa en un individuo. Por ejemplo, la variación en el **tamaño** de hojas, flores, frutos, semillas dentro del mismo individuo o la **cantidad** hojas, flores, frutos, semillas en tiempos distintos. Este tipo de variación es común en plantas y es un componente importante de la variación total pero raramente se considera en los análisis. Carlos Herrera ha demostrado claramente que este componente no solamente es parte de la variación total de las especies pero es importante para entender los procesos ecológicos y evolutivos (Herrera, 2009). En adición cuando uno compara la variación total por la variación sub-individual, la variación sub-individual es mucho más grande que la variación entre individuos y poblaciones. Esta variación al conocimiento de los presentes autores nunca ha sido incluido en análisis de dinámica poblacional y integrado dentro un PPM. En un estudio del tamaño de las flores en *Lepanthes rupestris* se observó que la variación en el tamaño de flores disminuye a largo de la inflorescencia y que la probabilidad de remoción de pollinia y de deposición de estas sobre el estigma no siguen el mismo patrón, la probabilidades de remoción de pollinia aumenta con flores más pequeñas pero la probabilidad de frutos disminuye (Tremblay, 2006). Por consecuencia, cuando se recolecta la información sobre el esfuerzo reproductivo de una especie, puede ser que la variación sub-individual impacta los estimados de la matriz de transiciones debido que las flores en este periodo eran de diferentes tamaños. Las inflorescencias de *Lepanthes* pueden ser activas produciendo flores por meses y años (Tremblay, comm. personal).

18.1.1.2 La variación entre individuos

La variación entre individuos es la diferencias que se observa entre individuos de una misma población. Por ejemplo, la variación en el tamaño de los individuos, cantidad de hojas, cantidad de flores, cantidad de frutos entre individuos de una misma población influye en la probabilidad de sobrevivir, crecer y reproducirse. La variación entre individuos de diferentes tamaños o etapas impacta grandemente la supervivencia, crecimiento y reproducción de los individuos. Los trabajos de Harper y otros han demostrado que esa variación es común en las plantas (Harper, 1977) y típicamente es más importante que la edad de los individuos en la mayoría de las plantas. En orquídea un ejemplo de esa variación es que la mayoría de los individuos reproductivos en una población no produce frutos (Ackerman et al., 2020).

18.1.1.3 La variación entre poblaciones

La variación entre poblaciones es la variación que se observa entre grupos de individuos de una misma especie en diferentes sitios. Poblaciones distintas pudiese ser influenciada por las diferencias abióticas y interacciones biótica única a cada población. Esa variación pudiese influenciar la dinámica de cada población y la dinámica de la especie en general. La diferencias entre poblaciones pudiese ser influenciado por condiciones específicas como la variación genéticas entre poblaciones, variación en el abiótica (recursos como el agua,

nitrógeno, luz), variación en la interacción biótica (ejemplo; micorriza, diversidad y cantidad de polinizadores, tipo de forófitos), variación en la historia de la población (procesos de sucesión), entre otros factores, en adición que la plasticidad fenotípica que se define como la interacción del ambiente sobre la expresión genética (Nicotra et al., 2010). Sin duda las variables abióticas y bióticas pueden influenciar las transiciones, estasis y reproducción de forma diferencial entre las diferentes etapas del ciclo de vida de la especie.

18.1.1.4 La variación entre tiempo

Este componente de variación incluye la variación típicamente relacionado a la variación *abiótica* que cambia de un periodo de tiempo a otro, por ejemplo el efecto de la cantidad de lluvia, números de días sin lluvia, temperatura entre muchas otras variables. Pero no se debería limitar a considerar solamente la variación abiótica en tiempo ya que la variación *biótica* también puede cambiar de un periodo de tiempo a otro. Por ejemplo la densidad y/o composición de especies en una comunidad cambia de un periodo de tiempo incluso la variación de patógenos y otras interacciones bióticas alrededor de la especie de interés. Todo lo anterior puede influenciar la dinámica y las estimaciones de los parámetros de la matriz. Por ejemplo considera la variación en presencia de herbívoros o patógenos que cambia de un periodo de tiempo resultando en variación en la competencia inter-específica. Por consecuencia la variación en tiempo es mucho más que la variación *abiótica* en tiempo. Allí uno también tiene que incluir el efecto de bonanza (eventos raros positivos, ejemplo: reclutamiento excepcional en unos años) (Antonini, Dirzo & Cassia Quitete-Portela, 2020) y catástrofes (eventos raros negativos, ejemplo: huracanes, mortandad de un hospedero) (Hiernaux et al., 2009) que puede influenciar la dinámica de la especie de interés. Un ejemplo drástico de su impacto es la mortandad casi completa de epífitas al pasar huracanes fuertes (Goode & Allen, 2008) o que el efecto es diferencial entre especies o el sustrato (Rodríguez-Robles, Ackerman & Meléndez, 1990).

18.1.1.5 Variación en tamaño de muestra pequeña

La gran mayoría de los estudios usando MPP son para evaluar la probabilidad de supervivencia en una especie en peligro de extinción. La razón principal de estos estudios es que queda muy pocos individuos en la población o pocas poblaciones y esas poblaciones son considerando a riesgosos.

Por ejemplo si tuviésemos en una población solamente de un adulto y este adulto sobrevive de un año a otro entonces la probabilidad de supervivencia es 1.0. Pero si tuviésemos solamente un adulto y este adulto muere entonces la probabilidad de supervivencia es 0.0. Las probabilidades de supervivencia pueden ser solamente 1.0 o 0.0 respectivamente y otros valores no son posibles, pero la interpretación biológica es sesgada, porque ya hay solamente dos alternativas. Pero si tuviésemos 1,000 o 10,000 individuos es muy poco probable que todos se mueren o todos sobreviven, y hay muchas alternativas posibles. Este es un ejemplo extremo pero ilustra claramente el problema de estimar la probabilidad de supervivencia y transiciones en una población con un tamaño de muestra pequeña y puede resultar en estimados sesgados.

En las próximas secciones vemos métodos de simulaciones y estimaciones de intervalos de confianza para abordar la variación biológica en tiempo y espacio y la variación por el tamaño de muestra pequeña.

18.2 Introducción a los métodos de simulaciones

Los métodos de simulaciones para estimar la variación en los parámetros tanto de la matriz como el crecimiento poblacional varia mucho. Lo que es consistente es que se utiliza datos disponible para hacer simulaciones y estimar la variación en los parámetros. En otra palabra se usa la variación entre los elementos de múltiples matrices de transición en tiempo o espacio o el tamaño de muestra para hacer simulaciones y estimar la dispersión en los parámetros. La manera de observar la variación puede asumir diferentes formas, por ejemplo, la variación en los parámetros de la matriz de transición puede ser expresado como una distribución normal (distribución en forma de campana), una distribución de Poisson (Datos con valores discretos, 0, 1, 2...ect), una distribución binomial (distribución donde hay solamente dos alternativas) o beta (distribución donde la distribución es limitada a los valores entre y inclusivo 0 a 1), entre otras distribuciones. Reconociendo el tipo de variación en los parámetros de la matriz de transición es importante para escoger el método de simulaciones y estimaciones de intervalos de confianza y reconocer sus limitación y su interpretación.

18.3 Estocasticidad espacial

En este caso vemos el efecto de la variación espacial en la probabilidad en los estimados. Aquí nos interesa descubrir y cuantificar cuan variable son las poblaciones una del otro. El objetivo es determinar si las poblaciones se comporta similar una del otro o varía mucho de un sitio al otro.

18.3.1 Entrada de datos

El primer paso es definir la diferentes matriz, una por cada periodo de tiempo. En el siguiente script se enseña como entrar los datos para múltiples matrices en un solo objeto. Nota que es una lista de matriz.



Figura 18.1: *Serapia cordigera*. Foto: Guiseppe Pelligrino

Los datos provienen de un estudio de la dinámica de una población de *Serapia cordigera* de 1999 al 2012 evaluando el impacto antropogénico sobre la dinámica de la población (Pellegrino & Bellusci, 2014). En este caso se emplea solamente 6 matrices de transición de la población de *Serapia cordigera* en 1999, tres de estas son poblaciones que tienen impacto antropogénico (A1, A2 y A3) y tres poblaciones naturales, sin impacto antropogénico (N1, N2, N3). Nota que se construye una lista (list()) de matriz de transición, una por cada periodo de tiempo.

```
Serapia<-list(
  A1_1999=matrix(c(
0.745,  0.152,  0.452,  0.564,
0.125,  0.000,  0.000,  0.000,
0.000,  0.321,  0.205,  0.342,
0.200,  0.365,  0.205,  0.185
),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                c("latente", "plantula", "rosetta", "con flor"))
```

```

    )
  ),
  A2_1999=matrix(c(
0.648, 0.203, 0.414, 0.604,
0.188, 0.000, 0.000, 0.000,
0.000, 0.342, 0.198, 0.377,
0.242, 0.264, 0.225, 0.191
),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                c("latente", "plantula", "rosetta", "con flor"))
  )
),
  A3_1999=matrix(c(
0.544, 0.223, 0.364, 0.498,
0.148, 0.000, 0.000, 0.000,
0.000, 0.249, 0.243, 0.287,
0.242, 0.303, 0.210, 0.101
),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                c("latente", "plantula", "rosetta", "con flor"))
  )
),
  N1_1999=matrix(c(
0.287, 0.271, 0.054, 0.107,
0.318, 0.000, 0.000, 0.000,
0.000, 0.438, 0.228, 0.273,
0.111, 0.512, 0.585, 0.542
),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                c("latente", "plantula", "rosetta", "con flor"))
  )
),
  N2_1999=matrix(c(
0.299, 0.253, 0.066, 0.182,
0.324, 0.000, 0.000, 0.000,
0.000, 0.461, 0.222, 0.264,
0.339, 0.568, 0.554, 0.547
),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                c("latente", "plantula", "rosetta", "con flor"))
  )
)

```

```

    )
  ),
  N3_1999=matrix(c(
    0.245,    0.156,    0.052,    0.147,
    0.325,    0.000,    0.000,    0.000,
    0.000,    0.422,    0.305,    0.252,
    0.210,    0.465,    0.498,    0.485
  ),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
    c("latente", "plantula", "rosetta", "con flor")
  )
)
)

```

Serapia

\$A1_1999

	latente	plantula	rosetta	con flor
latente	0.745	0.152	0.452	0.564
plantula	0.125	0.000	0.000	0.000
rosetta	0.000	0.321	0.205	0.342
con flor	0.200	0.365	0.205	0.185

\$A2_1999

	latente	plantula	rosetta	con flor
latente	0.648	0.203	0.414	0.604
plantula	0.188	0.000	0.000	0.000
rosetta	0.000	0.342	0.198	0.377
con flor	0.242	0.264	0.225	0.191

\$A3_1999

	latente	plantula	rosetta	con flor
latente	0.544	0.223	0.364	0.498
plantula	0.148	0.000	0.000	0.000
rosetta	0.000	0.249	0.243	0.287
con flor	0.242	0.303	0.210	0.101

\$N1_1999

	latente	plantula	rosetta	con flor
latente	0.287	0.271	0.054	0.107
plantula	0.318	0.000	0.000	0.000
rosetta	0.000	0.438	0.228	0.273
con flor	0.111	0.512	0.585	0.542

\$N2_1999

	latente	plantula	rosetta	con flor
latente	0.299	0.253	0.066	0.182
plantula	0.324	0.000	0.000	0.000
rosetta	0.000	0.461	0.222	0.264
con flor	0.339	0.568	0.554	0.547

\$N3_1999

	latente	plantula	rosetta	con flor
latente	0.245	0.156	0.052	0.147
plantula	0.325	0.000	0.000	0.000
rosetta	0.000	0.422	0.305	0.252
con flor	0.210	0.465	0.498	0.485

18.3.1.1 Simulaciones con igual probabilidad de selección

Si uno asume que hay igual cantidad de poblaciones afectada de forma antropogénicas y naturales entonces se puede hacer un análisis de la variación espacial en la probabilidad de supervivencia. Se puede simular el crecimiento con igual probabilidad de selección de las matrices de transición. En otra palabra cada matriz sera seleccionado al azar 1/6 de las veces. Este supuesto es razonable si uno asume que hay igual cantidad de poblaciones afectada de forma antropogénicas y naturales. El objetivo es ver la variación en la probabilidad de supervivencia en la población de *Serapia cordigera* en 1999 o mejor cual seria el tamaño de la poblacional típica de la especie si la especie se comporta como las siguientes matrices (Pellegrino & Bellusci, 2014).

La función `stoch.projection` del paquete `popbio` permite hacer simulaciones de la dinámica de una población y da una lista de la cantidad de individuos esperado por cada etapa de la vida. Comenzamos por definir el tamaño de la población inicial por etapa de la vida, `n`, el nombre de las etapas de la vida y luego usamos la función `stoch.projection` para hacer las simulaciones.

La función necesita tres argumentos, la lista de matrices de transición, el tamaño de la población inicial por etapa de la vida y el número de repeticiones. En este caso se usa 1000 repeticiones para tener una buena estimación de la variación en el tamaño de la población esperado por etapa de la vida. La función devuelve una lista con las simulaciones del tamaño de la población esperado por etapa de la vida.

```
n <- c(2, 0, 4, 99) # corresponde a la cantidad de individuos por etapa en la publicación
names(n) <- c("latente", "plantula", "rosetta", "con flor")
Serapia.eq <- stoch.projection(Serapia, n, nreps=1000) # simulación con igual probabilidad
head(Serapia.eq) # vemos las primeras 6 simulaciones de los tamaños de muestra esperada
```

	latente	plantula	rosetta	con flor
[1,]	1.5351391	1.44175492	1.1371919	2.7418122
[2,]	2.6404074	0.93329296	3.1034599	7.3262815
[3,]	0.9097668	0.06067032	0.4410205	0.3683167
[4,]	1.6679780	0.12678756	0.7885516	0.6885703
[5,]	1.8974614	1.66764305	0.9636452	2.4479828
[6,]	1.5443614	0.09103492	0.7615731	0.5906093


18.3.2 Cual es la distribución de la cantidad de individuos esperado.

Para observar cuantos individuos hubiese en el futuro de la población de *Serapia cordigera* si la especie se comporta como las matrices de transición. Se observa que en la poblaciones tendrían pocos individuos típicamente menor de 2-3 individuo todas las etapas irrelevante si fuesen latente, plántula, rosetta o con flores.



Figura 18.2: *Serapia cordigera*. Foto: Guiseppe Pelligrino


```
Serapia.eq=clean_names(as.data.frame(Serapia.eq)) # convertir la lista de matrices en un
Serapia.eq %>%
  gather(key="etapa", value="individuos") %>% # convertir el data frame de formato ancho
  mutate(etapa=factor(etapa, levels=c("plantula", "latente", "rosetta", "con_flor"))) %>%
  ggplot(aes(x=individuos))+
  geom_histogram(bins=30, aes(fill="blue"), color="white")+
  facet_wrap(~etapa, scales="free")+
  rlt_style_fill()+
  labs(title="Distribución de número de individuos esperado de *Serapia cordigera*",
       x="Número de individuos", y="Frecuencia")+
  theme(title = element_markdown())
```




En la siguiente figura se suma el total de individuos por simulación es una medida de la cantidad de individuos esperado en el futuro. En el siguiente gráfico se muestra la distribución de la cantidad de individuos esperado en el futuro de la población de *Serapia cordigera* si la especie se comporta como las matrices de transiciones arriba y seleccionado al azar por la misma probabilidades. Se observa que la mayoría de las simulaciones tienen menos de 10 individuos en el futuro.

```
Serapia_eq_T=Serapia.eq %>%
  mutate(total=rowSums(across(where(is.numeric)))) # sumar la cantidad de individuos en

ggplot(Serapia_eq_T,aes(x=total))+
  geom_histogram(bins=30, aes(fill="blue"), color="white")+
  rlt_style_fill()+
  labs(title="Distribución de número de individuos esperado de *Serapia cordigera*",
       x="Número de individuos", y="Frecuencia")+
  theme(title = element_markdown())
```

```
rlt_style_fill()+
labs(title="Distribución de total de individuos esperado de *Serapia cordigera*",
      x="Número total de individuos por simulación", y="Frecuencia")+
theme(title = element_markdown())+
theme(legend.position = "none")
```



18.4 Simulaciones con diferente probabilidad de selección

La probabilidad de selección de las matrices de transición no tiene que ser igual. En el siguiente script se muestra como hacer simulaciones con diferente probabilidad de selección de las matrices de transición. En este caso se asume que hay las 3 poblaciones afectada de forma antropogénicas y que estas son más común (poblaciones afectada antropogenicamente) que las poblaciones naturales. Las 3 poblaciones naturales son poblaciones raras y poco común. En la sección del script vemos que ahora las poblaciones afectada de forma antropogénicas son seleccionadas con una probabilidad de 0.85 ($.30 + .30 + .25$) y las poblaciones naturales con una probabilidad de 0.15. En otra palabra las poblaciones naturales son muy raras, y la especie es dominada por sitio donde la especie es afectada de forma antropogénicas. **Importante este es una simulación y no refleja la realidad de la especie ni la publicación.**

```
n <- c(2, 0, 4, 99) # población inicial por etapa
names(n) <- c("latente", "plantula", "rosetta", "con flor")
Serapia.uneq <- stoch.projection(Serapia, n, nreps=1000, prob=c(.3, .3, .25, .05, .05, .05))

head(Serapia.uneq) # vemos las primeras 6 simulaciones de tamaño de muestra
```

```
      latente plantula rosetta con flor
[1,] 20.055549 2.2048440 4.559853 6.984697
[2,]  5.319664 0.9526584 1.183326 2.309366
[3,] 35.108130 6.4697305 7.431945 15.332456
[4,]  3.703390 1.3322204 4.324923  9.132804
[5,]  8.003230 1.3685536 1.995616  3.576875
[6,]  7.722023 1.2973591 1.956049  3.390097
```


18.4.1 Comparar la distribución de cantidad de individuos esperado por simulaciones

Ahora vamos a solapar las dos distribuciones (la de selección por igual y por poblaciones mayormente impactado por humanos) para ver si hay una diferencia en la distribución de tamaño de muestra entre las dos simulaciones. Los resultados de la simulaciones sugiere que las poblaciones dominado antropogénicas (rojo) tienen una mayor cantidad de individuos en el futuro si las poblaciones tienen igual de probabilidades (aquamarine).

```
Serapia.uneq=clean_names(as.data.frame(Serapia.uneq))

Serapia.uneq_T=Serapia.uneq %>%
  mutate(total=rowSums(across(where(is.numeric))))

ggplot(Serapia.uneq_T, aes(total))+
  geom_histogram(bins=30, aes(fill="blue"), color="white")+
  geom_histogram(data=Serapia_eq_T, aes(x=total), bins=30, fill="aquamarine", color="black",
    rlt_style_fill())+
  labs(title="Distribución del total de individuos esperado de *Serapia cordigera*",
    x="Número total de individuos por simulación", y="Frecuencia")+
  theme(title = element_markdown())+
  theme(legend.position = "none")
```



18.4.1.1 Simulación de crecimiento poblacional de *Serapia cordigera*

En el siguiente script podemos evaluar el crecimiento poblacional y su variación en el espacio.

Nota aquí se calcula el log(crecimiento poblacional estocástica) de la especie de *Serapia cordigera* por aproximación y simulaciones siguiendo la formula de Tuljapukar (Tuljapurkar, 2013). Se puede ver que la especie tiene un crecimiento poblacional negativo en la mayoría de las simulaciones. Esto sugiere que la especie esta en declive. Pero también se puede ver que hay una variación en el crecimiento poblacional de la especie. El script incluye un parámetro para indicar por cuanto tiempo queremos que la simulación ocurra, **maxt**=, en esta caso se simula por 50 periodos de tiempo, si no se añade nada la simulación dura por 50000 periodos de tiempo. Nota que **maxt** es en el tiempo de periodo de la matriz de transición, si esta fue construida en un periodo de meses, entonces la simulación es ese intervalo de tiempo.

Cuando se usa el log de crecimiento poblacional estocástica se calcula

$$r$$

, ese valor es $r = \ln(\lambda)$ y r se interpretación de forma diferentes que los valores de lambda,

- $r = \log(\text{crecimiento poblacional estocástica}) > 0$ la población crece
- $r = \log(\text{crecimiento poblacional estocástica}) < 0$ la población decrece
- $r = \log(\text{crecimiento poblacional estocástica}) = 0$ la población es estable

El crecimiento estocástico de las poblaciones de *Serapia cordigera* en 1999 es negativo, sugiere que la especie esta en declive. Pero también se puede ver que hay una variación en el crecimiento poblacional de la especie. Se usa la función *stoch.growth.rate*

Simulaciones por selección de matriz con igual probabilidad

- el crecimiento es negativo y los intervalos de confianza también, dando confianza que la especie esta en declive.

```
SGR_eq=stoch.growth.rate(Serapia, maxt=50, verbose=TRUE) # matrices seleccionado con igu
```

Calculating stochastic growth at time 1

```
SGR_eq
```

```
$approx
```

```
[1] -0.06760619
```

```
$sim
```

```
[1] -0.06569693
```

```
$sim.CI
```

```
[1] -0.09559814 -0.03579571
```

18.4.2 Simulaciones por selección de matriz con diferente probabilidad

- el crecimiento es negativo y los intervalos de confianza solapa el cero, sugiere que hay variación en el crecimiento poblacional de la especie y que no hay evidencia que la especie esta en declive ni aumentando (es estable). La interpretaciones aquí es que si la especie es dominada por poblaciones con impacto antropogénico tienen un crecimiento poblacional no negativo.

```
SGR_uneq=stoch.growth.rate(Serapia, maxt=50, prob=c(.3, .3, .25, .05, .05, .05), verbose=
```

```
SGR_uneq
```

```
$approx
```

```
[1] -0.02988694
```

```
$sim
[1] -0.02584146

$sim.CI
[1] -0.053560959  0.001878048
```

Para convertir el log(crecimiento poblacional estocástica) a lambda se usa la siguiente formula e^r donde r es el log(crecimiento poblacional estocástica). Como ejemplo se muestra la metodología con las simulaciones con probabilidad desigual de selección de las matrices de transición.

18.4.2.1 Conversión de r a λ

Lambda Igual de probabilidades

```
exp(SGR_uneq$sim) # matrices seleccionado con igual probabilidad
```

```
[1] 0.9744896
```

```
exp(SGR_uneq$sim.CI[1]) #El intervalo de confianza inferior
```

```
[1] 0.9478482
```

```
exp(SGR_uneq$sim.CI[2]) #El intervalo de confianza superior
```

```
[1] 1.00188
```

18.4.3 Impacto antropogénico vs poblaciones naturales

Los análisis anteriores no separan las matrices de transición por el impacto antropogénico versus las poblaciones naturales. En el siguiente script se muestra como hacer simulaciones y estimar el crecimiento poblacional de las poblaciones afectada de forma separada.

- Separamos las matrices de transición en dos grupos, uno para las poblaciones afectada de forma antropogénicas y otro para las poblaciones naturales.


```
Serapia_A = Serapia[1:3] # poblaciones afectada de forma antropogénicas
Serapia_N= Serapia[4:6] # poblaciones naturales
```

Asumimos una probabilidad igual de selección por cada simulaciones en ambos escenarios

```
n <- c(2, 0, 4, 99) # corresponde a los datos de la especie en la publicación del año 2
names(n) <- c("latente", "plantula", "rosetta", "con flor")
Serapia.eq_A <- stoch.projection(Serapia_A, n, nreps=1000)
Serapia.eq_N <- stoch.projection(Serapia_N, n, nreps=1000)
```

Convertir las simulaciones de las matrices de transición en un data frame y limpiar los nombres de las columnas. Luego sumar el total de individuos por simulación para cada etapa de la vida. Esto es necesario para poder visualizar el tamaño poblacional esperado por etapa de la vida. El resultado del análisis es que las poblaciones afectada de forma antropogénicas tienen un estimado de tamaño de poblacional más grande que las poblaciones naturales.


```
Serapia.eq_A=clean_names(as.data.frame(Serapia.eq_A)) # limpiar los nombres de las columnas
Serapia.eq_N=clean_names(as.data.frame(Serapia.eq_N))

Serapia_eq_A=Serapia.eq_A %>%
  mutate(total=rowSums(across(where(is.numeric)))) # sumar la cantidad de individuos en cada etapa

Serapia_eq_N=Serapia.eq_N %>%
  mutate(total=rowSums(across(where(is.numeric))))
```

Visualizar el tamaño de poblacional esperado por etapa de la vida para las poblaciones afectada de forma antropogénicas y naturales. Se observa que las poblaciones afectada de forma antropogénicas tienen un tamaño de poblacional más grande que las poblaciones naturales. la poblaciones con efecto antropogénico tienen a ser de mayor cantidad.

```
diverging= c("#009392", "#CF597E", "#E9E29C", "#39B185", "#EEB479", "#9CCB86")
ggplot(Serapia_eq_N, aes(total))+
  geom_histogram(fill= "#009392", color="white", bins=30, alpha=.5)+
  geom_histogram(data=Serapia_eq_A, aes(x=total),
    fill="#CF597E", color="white", bins=30, alpha=.5)+
  theme_minimal()+
  labs(title="Distribución de total de individuos esperado de *Serapia cordigera*",
    x="Número total de individuos por simulación", y="Frecuencia")+
  theme(title = element_markdown())
```



18.5 Estocasticidad temporal



Figura 18.3: *Serapias cordigera*. Foto: Guiseppe Pelligrino

El objetivo de evaluar la variación en tiempo es para determinar si los efectos temporales son importante en predecir los cambios en el crecimiento o estabilidad poblacional. Seguimos con los datos *Serapias cordigera*, pero ahora evaluamos cual es el efecto de la variación en los parámetros de la matriz usando múltiple censos. Vemos el efecto de una esas población, por impacto antropogénico solamente de la población **A1** en los 13 años de muestreo comenzando en el 1999 al 2011, inclusivo.

El primer paso en entrar los datos en una lista de matrices de transición.

```
Serapia_tiempo<-list(
  A1_1999=matrix(c(
    0.745, 0.152, 0.452, 0.564,
    0.125, 0.000, 0.000, 0.000,
    0.000, 0.321, 0.205, 0.342,
    0.200, 0.365, 0.205, 0.185
  ),
  nrow=4, byrow=TRUE,
  dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
```

```

        c("latente", "plantula", "rosetta", "con flor")
    )
),
A1_2000=matrix(c(
0.578, 0.222, 0.394, 0.394,
0.188 ,0.000, 0.000, 0.000,
0.000 ,0.322, 0.254, 0.357,
0.244 ,0.314, 0.125, 0.302
),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
               c("latente", "plantula", "rosetta", "con flor")
)
),
A1_2001=matrix(c(
0.668, 0.122, 0.294, 0.401,
0.128, 0.000 ,0.000, 0.000,
0.000, 0.302 ,0.453, 0.366,
0.214, 0.364, 0.185, 0.207
),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
               c("latente", "plantula", "rosetta", "con flor")
)
),
A1_2002=matrix(c(
0.645, 0.222, 0.682, 0.504,
0.177, 0.000, 0.000, 0.000,
0.000, 0.421, 0.305, 0.382,
0.102, 0.355, 0.208, 0.208
),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
               c("latente", "plantula", "rosetta", "con flor")
)
),
A1_2003=matrix(c(
0.545, 0.113, 0.424, 0.424,
0.247, 0.000, 0.000, 0.000,
0.000, 0.166, 0.233, 0.277,
0.192, 0.253, 0.209, 0.212
),
nrow=4, byrow=TRUE,

```

```

    dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                  c("latente", "plantula", "rosetta", "con flor")
    )
  ),
  A1_2004=matrix(c(
    0.548,    0.191,  0.402,  0.527,
    0.327,    0.000,  0.000,  0.000,
    0.000,    0.338,  0.127,  0.394,
    0.211,    0.262,  0.296,  0.142
  ),
    nrow=4, byrow=TRUE,
    dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                  c("latente", "plantula", "rosetta", "con flor")
    )
  ),
  A1_2005=matrix(c(
    0.602,    0.153,  0.486,  0.562,
    0.224,    0.000,  0.000,  0.000,
    0.000,    0.491,  0.324,  0.304,
    0.139,    0.268,  0.294,  0.277
  ),
    nrow=4, byrow=TRUE,
    dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                  c("latente", "plantula", "rosetta", "con flor")
    )
  ),
  A1_2006=matrix(c(
    0.487,    0.471,  0.425,  0.607,
    0.318,    0.000,  0.000,  0.000,
    0.000,    0.438,  0.328,  0.373,
    0.211,    0.212,  0.285,  0.142
  ),
    nrow=4, byrow=TRUE,
    dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
                  c("latente", "plantula", "rosetta", "con flor")
    )
  ),
  A1_2007=matrix(c(
    0.544,    0.423,  0.374,  0.578,
    0.348,    0.000,  0.000,  0.000,
    0.000,    0.441,  0.248,  0.288,
    0.145,    0.203,  0.311,  0.201
  )

```

```

),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
              c("latente", "plantula", "rosetta", "con flor"))
),
A1_2008=matrix(c(
  0.568, 0.325, 0.294, 0.607,
  0.227, 0.000, 0.000, 0.000,
  0.000, 0.402, 0.553, 0.256,
  0.194, 0.364, 0.275, 0.217

),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
              c("latente", "plantula", "rosetta", "con flor"))
),
A1_2009=matrix(c(
  0.545, 0.356, 0.472, 0.398,
  0.225, 0.000, 0.000, 0.000,
  0.000, 0.322, 0.304, 0.452,
  0.110, 0.225, 0.298, 0.185

),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
              c("latente", "plantula", "rosetta", "con flor"))
),
A1_2010=matrix(c(
  0.399, 0.352, 0.486, 0.580,
  0.424, 0.000, 0.000, 0.000,
  0.000, 0.561, 0.312, 0.264,
  0.239, 0.168, 0.354, 0.247

),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
              c("latente", "plantula", "rosetta", "con flor"))
),
A1_2011=matrix(c(
  0.497, 0.352, 0.465, 0.622,

```

```

0.324, 0.000, 0.000, 0.000,
0.000, 0.361, 0.321, 0.264,
0.139, 0.368, 0.367, 0.177

),
nrow=4, byrow=TRUE,
dimnames=list(c("latente", "plantula", "rosetta", "con flor"),
              c("latente", "plantula", "rosetta", "con flor"))
)
)
)

#Serapia_tiempo

```

18.5.0.1 Simulaciones con igual probabilidad de selección.

El análisis evalúa la variación temporal en el crecimiento poblacional de la especie de *Serapia cordigera* en 1999 a 2012. Usando la función *stoch.projection* se observa la variación en cantidad de individuos por etapa.

```

n <- c(2, 0, 4, 99) # población inicial por etapa
names(n) <- c("latente", "plantula", "rosetta", "con flor")
Serapia_tiempo_eq <- stoch.projection(Serapia_tiempo, n, nreps=5000) # simulación con
head(Serapia_tiempo_eq) # vemos las primeras 6 simulaciones de tamaño de muestra

```

	latente	plantula	rosetta	con flor
[1,]	37.03646	10.12951	9.667055	16.92036
[2,]	86.43286	28.94830	24.253317	34.93329
[3,]	71.43392	16.33676	28.971256	34.75091
[4,]	70.21941	15.72712	18.990694	35.15035
[5,]	107.73327	20.63149	38.472818	56.28718
[6,]	50.90065	17.45165	16.627220	22.88275

Para evaluar el cambio de crecimiento poblacional en la especie de *Serapia cordigera* en 1999 a 2011 se usa la función *stoch.growth.rate*.

Se observa que el crecimiento poblacional es cerca de cero en la mayoría de las simulaciones, esto sugiere que la especie no está en declive ni creciendo. Los intervalos de confianza solapan el cero dando apoyo que el crecimiento temporal de la población no es diferente de estable durante este periodo de tiempo.

Nota que se puede cambiar la probabilidades de selección de las matrices de transición, en este caso se asume que hay igual cantidad de poblaciones afectada de forma antropogénicas y naturales. Pero considera por ejemplo que hay eventos abióticos como temperatura o lluvia fuera de lo común en un año, entonces se puede cambiar la probabilidad de selección de las matrices de transición para evaluar el efecto de estos eventos de cambio climatológico en el crecimiento poblacional de la especies. Si por ejemplo en el área donde estas especies hay predicción que un factor abiótico, por ejemplo reducción en lluvia (aumento en sequía) en las próximas décadas se pudiese cambiar la probabilidad de selección para de las matrices que son en periodos de sequía y que sean seleccionado más frecuentemente en la simulaciones. El objetivo es de simular los efectos de cambio en tiempo sobre el crecimiento poblacional de la especies basado en un patrón esperado de factores abióticos o bióticos.

```
SGR_Temp_eq=stoch.growth.rate(Serapia_tiempo, maxt=50) # matrices seleccionado con igual
```

Calculating stochastic growth at time 1

```
SGR_Temp_eq
```

```
$approx
[1] 0.002712947
```

```
$sim
[1] 0.01390283
```

```
$sim.CI
[1] -0.01217765 0.03998331
```

```
# Conversión a valores de Lambda
```

```
exp(SGR_Temp_eq$sim) # Lambda de matrices seleccionado con igual probabilidad
```

```
[1] 1.014
```

```
exp(SGR_Temp_eq$sim.CI[1]) #Lambda del intervalo de confianza inferior
```

```
[1] 0.9878962
```

```
exp(SGR_Temp_eq$sim.CI[2]) # Lambda del intervalo de confianza superior
```

```
[1] 1.040793
```

tipo	lambda	CI_inf	CI_sup	diff_ci
Espacial	0.9364146	0.9088292	0.9648374	0.05600821
Temporal	1.0139999	0.9878962	1.0407934	0.05289721

18.5.0.2 Comparación entre la variaciones espacial y temporal

Comparar la variación temporal en el crecimiento poblacional de la especie de *Serapia cordigera* en 1999 a 2011 con la variación espacial.

Lo que se observa es que la variación temporal y la variación espacial es más o menos igual (el rango de variación, diff), pero que hay menos variación temporal que espacial. Por lo menos para los datos seleccionado de (Pellegrino & Bellusci, 2014) la variación temporal no es tan grande como la variación espacial y solapa el lambda de 1, al contrario la variación espacial no solapa el lambda de 1 (ambos CI son menores de 1, sugiriendo una reducción posible de las poblaciones). Note que no usamos todos los datos de Pellegrino (Pellegrino & Bellusci, 2014) pero un sub-grupo y por consecuencia el análisis es sesgado.

```
Tabla_resultado=tribble(
  ~tipo, ~lambda, ~CI_inf, ~CI_sup, ~diff_ci,
  "Espacial", exp(SGR_eq$sim), exp(SGR_eq$sim.CI[1]), exp(SGR_eq$sim.CI[2]), exp(SGR_eq$sim.CI[3]),
  "Temporal", exp(SGR_Temp_eq$sim), exp(SGR_Temp_eq$sim.CI[1]), exp(SGR_Temp_eq$sim.CI[2]), exp(SGR_Temp_eq$sim.CI[3])
)
gt::gt(Tabla_resultado)
```


18.5.1 Comparación visual de la variación temporal y espacial en un gráfico

Observación de la variación temporal y espacial en el crecimiento poblacional de la especie de *Serapia cordigera* en un gráfico.

Se nota que el crecimiento poblacional intrínseco de la especie de *Serapia cordigera* es negativo en la mayoría de las simulaciones cuando se evalúa múltiple poblaciones, pero la población **A1** en general tiene un crecimiento positivo o es estable cuando se evalúa tomando en cuenta la variación temporal. La linea horizontal representa el crecimiento poblacional de 1, si el crecimiento poblacional es mayor de 1 la población crece, si es menor de 1 la población decrece. En el análisis temporal vemos que el intervalo de confianza solapa el 1, sugiere que no hay evidencia que el crecimiento poblacional es diferente de estable.

```
ggplot(Tabla_resultado, aes(x=tipo, y=lambda, color=tipo))+
  geom_point(stat="identity", colour="black")+
```

```
geom_errorbar(aes(ymin=CI_inf, ymax=CI_sup), width=.2)+
rlt_style_colour()+
geom_hline(yintercept=1, linetype="dashed", color = "red")+
labs(title="Comparación de simulaciones de crecimiento poblacional de *Serapia cordigera",
labs(x="Tipo de variación", y="Crecimiento poblacional")+
theme(title = element_markdown())+
scale_y_continuous(limits = c(0.90, 1.1))
```



18.6 Estocasticidad demográfica

En esta sección vemos el efecto del tamaño de muestra sobre los parámetros de la matriz de transición.

Este método usa un acercamiento Bayesiano y una distribución de probabilidad beta para estimar los parámetros de la matriz de transición conocida como la distribución Dirichlet múltiples para grupos discretos. Primero vemos a que se refiere un análisis Bayesiano y la función Dirichlet. A lo que corresponde al presenta análisis Bayesiano, incluimos una previa al análisis, en otra palabra, se usa información previa para incluirlos en los cálculos para estimar los parámetros, se llaman los estimados posteriores. En nuestro caso haremos una previa con poco peso, en otra palabra, no influirá mucho (o casi nada) en los resultados. El concepto de previa es importante en el análisis Bayesiano, es inherente a la filosofía de la estadística Bayesiana. Se asume que información anterior al estudio ayuda a tomar decisión

en los cálculos los datos actuales. Como biólogos, siempre tenemos información previa, por ejemplo, sabemos que la probabilidad de que un individuo muera no es cero, aunque esto es evidente es una información adquirido por nuestra experiencia previa. Ahora cual es la probabilidad exacta de la muerte de un individuo, eso es lo que se estima en el análisis Bayesiano tomando en cuenta tanto la información previa y la información recolectado de un estudio.

La función Dirichlet es una expansión de una función bien básica de probabilidad, usando una distribución beta. La función beta es una distribución de probabilidad continua en el intervalo de $[0,1]$ y se usa para modelar la probabilidad de un evento binario. La función Dirichlet es una generalización de la función beta y se usa para modelar la probabilidad de un evento multinomial (múltiples grupos) donde la suma de cada probabilidades es igual a 1 y las probabilidades tienen que estar dentro del intervalo de $[0,1]$. En otra palabra no puede haber valores menores de 0 o mayores de 1, incluyendo la suma de estos.

Comenzamos con lo más básico, probabilidades de dos grupos. Consideramos un grupo de 10 individuos, si 6 de estos individuos sobreviven, cual es la proporción que no sobreviven. La probabilidad de sobrevivir es $p = 6/10$, entonces la probabilidad de no sobre vivir $\hat{p} = 1 - p$, porque siempre la suma de $p + \hat{p} = 1$.

Si tenemos tres grupos, digamos, plántulas que se quedan como plántula, que crecen a juveniles o que mueren. En este caso tenemos tres grupos (multinomial) y la probabilidad de que un individuo de las proporciones tiene que sumar a 1. En este caso la probabilidad de que un individuo se queda como plántula es $p_1 = 0.5$, la probabilidad de que un individuo crece a juvenil es $p_2 = 0.3$ y la probabilidad de que un individuo muere es $p_3 = 0.2$. La suma de estas probabilidades tiene que ser igual a 1, en otra palabra $p_1 + p_2 + p_3 = 1$.

La otra ventaja de usar la función Dirichlet es que se basa en la distribución beta. Este es una distribución donde tanto los parámetros como el promedio, y los intervalo de confianza son limitado a 0 y 1. Otra manera de decir lo mismo es que no se puede tener intervalos de confianza menos 0 o mayor de 1. Hagan el ejercicio mental de tratar de entender un intervalo de confianza con una probabilidad de -0.10. Nota que si uno usa una distribución normal, los intervalos de confianza pueden ser negativos o mayores de 1, lo que no tiene sentido biológico ni matemático en el contexto de probabilidad. De allí viene la ventaja de usar la distribución beta para calcular los parámetros y tener claro cual distribuciones se usa para estimar los parámetros.

18.6.1 Seleccionar una población de *Serapia cordigera*

Se selecciona la población A3 de *Serapia cordigera* para hacer el análisis. Esta población es una de las poblaciones afectada de forma antropogénicas, y tiene un tamaño de muestra pequeño, lo que hace que sea interesante para ver el efecto del tamaño de muestra en los parámetros de la matriz de transición.

```
n <- c(2, 0, 4, 99) # población inicial por etapa
names(n) <- c("latente", "plantula", "rosetta", "con flor")
Serapia_A3 <- splitA(Serapia$A3) # simulación solamente la matriz A3 de la lista de ma
```

18.6.2 Asignar una previa a los datos

En el siguiente paso vamos a asignar una previa a los datos. Estas previas proviene de Tremblay, no representa la visión de los autores del artículo. Se añade una previa también para la proporción de plantas que fallece en cada etapa (la quita fila). Nota que es importante que la suma de cada columna sea igual a 1. Típicamente uno debería obtener la previa de la literatura o de un especialista en la biología de la especie antes de la recolección de datos, pero en este caso no se tiene información previa.

```
RLT_Serapia_previa <- matrix(c(0.5, 0.1, 0.4, 0.4,
                               0.2, 0., 0.0, 0.0,
                               0.0, 0.025, 0.25, 0.3,
                               0.15, 0.05, 0.25, 0.2,
                               0.05, 0.025, 0.1, 0.1),
                              byrow = TRUE, nrow = 5, ncol = 4)
```

18.6.3 Obtener los intervalos de confianza (IC) para entradas de matriz individuales

La distribución posterior marginal de un elemento en un multinomio es una distribución beta, y usamos esto para obtener intervalos creíbles en nuestro tasas de transición. Podemos usar el tipo de retorno TN para obtener los parámetros de el multinomio deseado.

Nota que:

- TF tiene que ser una matriz dividido entre la transición y de fecundidad ($\text{matT} + \text{matF}$),
- N es el tamaño de muestra de cada etapa de la vida,
- P es la previa de la matriz de transición,
- priorweight es el peso de la previo (en este caso estamos dando muy poca importancia a la previa, como si fuese una décima de un individuo), lo que resulta en que los datos del campo domina el análisis.
- Regresa el posterior de la matriz de transición. Eso quiere decir que calcula los parámetros de la distribución beta para cada elemento de la matriz de transición tomando en cuenta tanto los valores de la matriz **TF** y la previa **P**.

En el script vemos los intervalos de confianza de la matriz de transición de *Serapia cordigera* en 1999 para la población A3.

Lo más dramático de ese primer análisis que que los intervalos de credibilidad son bien grandes, casi todos los intervalos de credibilidad **lcl** y **ucl** de muy cerca de cero a valores muy grande. Esto sugiere que hay mucha incertidumbre en los datos. Este resultado es esperado, porque la muestra es muy pequeña, solamente 2 individuos fueron muestreado en el campo de esta etapa.

```
TN <- fill_transitions(Serapia_A3, N=n, P = RLT_Serapia_previa, priorweight = .01, return=T)
a <- TN[,1] # cambie 1 a 2, 3 etc para obtener la distribución beta marginal de cada columna
b <- sum(TN[,1]) - TN[,1] # cambie 1 a 2, 3 etc para obtener la distribución beta marginal de cada columna
p <- a / (a + b)
lcl <- qbeta(0.025, a, b)
ucl <- qbeta(0.975, a, b)
A3=knitr::kable(sprintf("%.3f, %.3f, %.3f", p, lcl, ucl))

A3df_lat=round(data.frame(p, lcl, ucl), digits=3)
A3df_lat$etapa_futura <- c("latente", "plantula", "rosetta", "con flor", "fallece")
A3df_lat
```

	p	lcl	ucl	etapa_futura
1	0.544	0.038	0.984	latente
2	0.149	0.000	0.735	plantula
3	0.000	0.000	0.000	rosetta
4	0.241	0.000	0.844	con flor
5	0.066	0.000	0.544	fallece

Ahora vemos que pasa con la etapa que tenemos más datos, los adultos con flores. En este caso vemos que los intervalos de credibilidad son más pequeños, pero todavía son grandes, ya que el tamaño de muestra es de 99 para esta etapa.

```
TN <- fill_transitions(Serapia_A3, N=n, P = RLT_Serapia_previa, priorweight = 0.01, return=T)
a <- TN[,4] # cambie 1 a 2, 3 etc para obter la distribución beta marginal de cada columna
b <- sum(TN[,4]) - TN[,4] # cambie 1 a 2, 3 etc para obter la distribución beta marginal de cada columna
p <- a / (a + b)
lcl <- qbeta(0.025, a, b)
ucl <- qbeta(0.975, a, b)
A3=knitr::kable(sprintf("%.3f, %.3f, %.3f", p, lcl, ucl))

A3df=round(data.frame(p, lcl, ucl), digits=3)
A3df$etapa_futura <- c("latente", "plantula", "rosetta", "con flor", "fallece")
A3df
```

	p	lcl	ucl	etapa_futura
1	0.004	0.000	0.022	latente
2	0.000	0.000	0.000	plantula
3	0.287	0.203	0.379	rosetta
4	0.102	0.051	0.168	con flor
5	0.607	0.510	0.700	fallece

18.6.4 Impacto de tamaño de muestra en los intervalos de credibilidad

Como ejercicio, vemos que tipo de intervalos si tuviésemos tamaño de muestra de 500 individuos en la etapa de adulto. Nota que aun que los intervalos de credibilidad son más pequeños, no se debería asumir que no hay variación demográfica en la etapa de adulto, por procesos estocásticos.

```
n500 <- c(2, 0, 4, 500) # población inicial por etapa
TN <- fill_transitions(Serapia_A3, N=n500, P = RLT_Serapia_previa, priorweight = 0.01, r
a500 <- TN[,4] # cambie 1 a 2, 3 o 4 ect. para obtener la distribución beta marginal de
b500 <- sum(TN[,4]) - TN[,4] # cambie 1 a 2, 3 ect. para obtener la distribución beta mar
p500 <- a500 / (a500 + b500)
lcl <- qbeta(0.025, a500, b500)
ucl <- qbeta(0.975, a500, b500)
A3=knitr::kable(sprintf("%.3f, %.3f, %.3f", p, lcl, ucl))

A3df=round(data.frame(p, lcl, ucl), digits=3)
A3df$etapa_futura <- c("latente", "plantula", "rosetta", "con flor", "fallece")
A3df
```

	p	lcl	ucl	etapa_futura
1	0.004	0.000	0.011	latente
2	0.000	0.000	0.000	plantula
3	0.287	0.249	0.327	rosetta
4	0.102	0.077	0.130	con flor
5	0.607	0.564	0.649	fallece

18.6.5 Visualización de la distribución beta

Ahora vemos como se distribuye una distribución beta. Usamos los datos de la etapa de adulto con flores con 99 individuos. Se observa que ninguna de la transiciones o estasis tiene una distribución normal. La distribución que demuestra bien este patrón son los adultos con flores que pasan a latente. La línea roja vertical representa el promedio, o sea el valor en la matriz de transición.


```
a # los valores del shape alpha
```

```
[1] 0.396 0.000 28.710 10.197 60.687
```

```
b # los valores del shape beta
```

```
[1] 99.594 99.990 71.280 89.793 39.303
```

```
# Función para visualizar la distribution beta
```

```
plot_beta <- function(alpha, beta) {
  x <- seq(0, 1, length.out = 100)
  y <- dbeta(x, alpha, beta)
  data <- data.frame(x = x, y = y)
  ggplot(data, aes(x, y)) +
    geom_line()
}
```

```
# Distirbuciones beta
```

```
Latentes=plot_beta(0.396, 99.594)+
```

```
  xlim(0, .1)+
```

```
  labs(title = paste("Distribución de latentes \n (alpha =", 0.396, ", beta =", 99.594
```

```
    x = "Probabilidad", y = "Densidad")+
```

```
  theme(text = element_text(size = 6))+
```

```
  geom_vline(xintercept = 0.004, linetype = "dashed", color = "#009392")
```

```
Plantulas=plot_beta(0.000, 99.990)+
```

```
  xlim(0, .025)+ylim(0, .05)+
```

```
  labs(title = paste("Distribución de plántulas \n (alpha =", 0.000, ", beta =", 99.90
```

```
    x = "probabilidad", y = "Densidad")+
```

```
  theme(text = element_text(size = 6))+
```

```
  geom_vline(xintercept = 0.000, linetype = "dashed", color = "#009392")
```

```
Rosetta=plot_beta(28.710, 71.280)+
```

```
  xlim(0, .5)+
```

```
  labs(title = paste("Distribución de rosettas \n (alpha =", 28.710, ", beta =", 71.28
```

```
    x = "probabilidad", y = "Densidad")+
```

```
  theme(text = element_text(size = 6))+
```

```
  geom_vline(xintercept = 0.287, linetype = "dashed", color = "#009392")
```

```
Adultos=plot_beta(10.197, 89.793)+
```

```
  xlim(0, .27)+
```

```
  labs(title = paste("Distribución de Ind. con flores \n (alpha =", 10.197, ", beta =",
```

```
    x = "probabilidad", y = "Densidad")+
```


```

theme(text = element_text(size = 6))+
geom_vline(xintercept = 0.102, linetype = "dashed", color = "#009392")

Fallecidos=plot_beta(60.687, 39.303)+
  xlim(.40, .8)+
  labs(title = paste("Distribución de fallecidos \n (alpha =", 60.687, ", beta =", 39.303, ")"),
       x = "probabilidad", y = "Densidad")+
  theme(text = element_text(size = 6))+
  geom_vline(xintercept = 0.607, linetype = "dashed", color = "#009392")

ggarrange(Latentes, Plantulas, Rosetta, Adultos, Fallecidos, ncol=3, nrow=2)

```



```
ggsave("mi_gragico.tiff")
```

Saving 5.5 x 3.5 in image

18.7 Ventaja de usar simulaciones

La primera ventaja de usar métodos de análisis por simulaciones es que se puede calcular intervalos de confianza. Si los intervalos de confianza de λ solapa el uno (1) (o solapa el 0 para $\log \lambda$) entonces no hay evidencia de que el crecimiento poblacional es diferente de estable.

La segunda ventaja de usar simulaciones es que hay que recordar que los análisis están basados en datos limitados y que si hubiese más o menos datos para estimar los elementos de la matriz los parámetros de la matriz pudiesen ser diferentes. Entonces hay un componente de incertidumbre en los estimados de los parámetros de la matriz, los valores de promedio no recolectan esa variación entre individuos, tiempo y espacio.

La incertidumbre por causas intrínsecas (el individuo, genética, tamaño de muestra) y extrínsecas (hábitat, tiempo, variación en polinizadores, herbívoros, etc.) se evalúa usando análisis de variación espacial, temporal y demográficos. La incertidumbre en los parámetros de la matriz de transición se puede cuantificar con intervalos de confianza o el intervalo de credibilidad (concepto Bayesiano). Es de suma importancia que se evalúe la incertidumbre en los parámetros de la matriz de transición para tener un mejor entendimiento de donde proviene la variación y la incertidumbre en el crecimiento poblacional de una especie y saber si hay suficiente evidencia para tener confianza que la especie está en declive, crece o no.

